


Laporan UAS DAD KNN

Bryan Herdianto 2306210885

Link Google Colab

<https://colab.research.google.com/drive/1fV373i3cVOtBGYGgA1Tnn1IH1NznCQOh?usp=sharing>



The screenshot shows a Google Colab notebook interface. At the top, the title bar reads "Medical_Cost_KNN_Regression" with standard file editing icons. Below the title bar is a menu bar with "File", "Edit", "View", "Insert", "Runtime", "Tools", and "Help". A toolbar below the menu bar includes a search icon, "Commands", and buttons for "+ Code", "+ Text", and "Run all".

The notebook content is organized into sections on the right side of the interface:

- Medical Cost KNN Regression**: The main title of the notebook.
- Tujuan**: A section with a red target icon. The text reads: "Memprediksi biaya asuransi kesehatan menggunakan K-Nearest Neighbors (KNN) Regression, dengan validasi yang tepat melalui pipeline dan cross-validation."
- Deskripsi Kolom Dataset**: A section with a document icon containing a table of dataset columns and their descriptions.
- Import library**: A section with a dropdown arrow icon, containing text about importing libraries for model building.

Kolom	Deskripsi
age	Usia dari penerima manfaat utama (primary beneficiary).
sex	Jenis kelamin dari kontraktor asuransi: female atau male.
bmi	Body Mass Index - Indeks yang mencerminkan rasio berat terhadap tinggi badan (kg/m^2), idealnya antara 18.5 hingga 24.9.
children	Jumlah anak atau tanggungan yang ditanggung oleh asuransi kesehatan.
smoker	Status merokok dari individu: yes atau no.
region	Wilayah tempat tinggal penerima manfaat di AS: northeast, southeast, southwest, northwest.
charges	Biaya medis individu yang ditagihkan oleh perusahaan asuransi kesehatan (target variabel).

Import library

Kode ini mengimpor library-library penting untuk membangun model regresi menggunakan K-Nearest Neighbors (KNN). Kode akan menggunakan matplotlib.pyplot digunakan untuk visualisasi dan scikit-learn seperti train_test_split, ColumnTransformer, dan Pipeline untuk pembagian data, preprocessing, dan penyusunan alur kerja model.

Pengenalan Model

Model ini bertujuan memprediksi biaya asuransi kesehatan menggunakan K-Nearest Neighbors (KNN) Regression, dengan validasi yang tepat melalui pipeline dan cross-validation.

Kolom	Deskripsi
age	Usia dari penerima manfaat utama (primary beneficiary).
sex	Jenis kelamin dari kontraktor asuransi: <code>female</code> atau <code>male</code> .
bmi	Body Mass Index - Indeks yang mencerminkan rasio berat terhadap tinggi badan (kg/m^2), idealnya antara 18.5 hingga 24.9.
children	Jumlah anak atau tanggungan yang ditanggung oleh asuransi kesehatan.
smoker	Status merokok dari individu: <code>yes</code> atau <code>no</code> .
region	Wilayah tempat tinggal penerima manfaat di AS: <code>northeast</code> , <code>southeast</code> , <code>southwest</code> , <code>northwest</code> .
charges	Biaya medis individu yang ditagihkan oleh perusahaan asuransi kesehatan (target variabel).

Hasil GridSearchCV

GridSearchCV merupakan proses dari hyperparameter tuning untuk mencari parameter yang paling optimal agar model dapat menghasilkan nilai RMSE dan R2 yang paling tinggi. Berdasarkan hasilnya, kita bisa lihat bahwa jumlah neighbors yang paling cocok adalah 4 karena menghasilkan nilai R2 pada train dataset sebesar 0.67.

```
Best parameters: {'regressor__n_neighbors': 4, 'regressor__p': 1, 'regressor__weights': 'distance'}  
Best cross-validation R^2 score: 0.6743698255331694
```

Hasil RMSE dan R2 dari Model Baseline

Untuk kedepannya, model terbaik dari GridSearchCV akan dinamakan sebagai model baseline. Model ini diujikan pada test dataset dan berhasil menghasilkan nilai RMSE dan R2 sebagai berikut.


```
RMSE on test set: 6206.28  
R^2 on test set: 0.74
```

Hasil RMSE dan R2 yang dihasilkan sudah lumayan. Meskipun begitu, sebenarnya model masih bisa ditingkatkan dengan cara menghapus fitur, transformasi variabel target, menggunakan jenis model lain, dll.

Hasil Residual Plot dari Model Baseline

Pada residual plot, terlihat pola kurva atau fan-shaped pattern:

- Pada nilai target yang kecil (sekitar < 15.000), residu relatif rapat.
- Pada nilai target menengah hingga tinggi (> 20.000), residu menjadi semakin menyebar dan naik tajam.
- Ini menunjukkan heteroskedastisitas, di mana varian error meningkat seiring nilai target.
- Alhasil, model ini kurang akurat untuk nilai charges yang tinggi.



Optimasi dengan Penghapusan Fitur

Pertama-tama, akan digunakan Pearson Correlation untuk mencari korelasi antara data numerik beserta data kategorik dengan variabel target.

```
Correlation with 'charges':  
charges      1.000000  
age          0.299008  
bmi          0.198341  
children     0.067998  
Name: charges, dtype: float64
```

```
Top correlations with 'charges' from categorical variables:  
smoker_yes      0.787251  
region_southeast 0.073982  
sex_male        0.057292  
region_northeast 0.006349  
region_northwest -0.039905  
region_southwest -0.043210  
sex_female      -0.057292  
smoker_no       -0.787251  
Name: charges, dtype: float64
```

Berdasarkan hasil di atas, maka diputuskan bahwa fitur “children”, “region”, dan “sex” akan dihapus karena memiliki korelasi mutlak kurang dari 0,1.

Hasil Model dengan Penghapusan Fitur

Penghapusan masing-masing fitur tunggal (children, region, atau sex) sudah meningkatkan performa model, baik dari sisi RMSE (Root Mean Square Error) maupun R^2 (R-squared). Namun, kombinasi penghapusan dua atau tiga fitur memberikan peningkatan performa yang lebih signifikan.


Model terbaik dicapai saat ketiga fitur dihapus, yaitu:

- RMSE: 4892.64
- R^2 : 0.84

Hal ini menunjukkan bahwa penghapusan fitur-fitur yang tidak berkorelasi justru membantu model menjadi lebih fokus pada fitur yang relevan, sehingga meningkatkan akurasi prediksi.

Fitur Dihapus	RMSE	R^2
Tanpa penghapusan	6206.28	0.74
children	5845.50	0.77
region	5552.14	0.79
sex	5579.20	0.79
children, region	5300.36	0.81
children, sex	5037.46	0.83
region, sex	5010.56	0.83
children, region, sex	4892.64	0.84

Tuning Plot: k vs R2



Grafik ini menunjukkan hubungan antara jumlah neighbors (k) dalam KNN dan kinerja model (R² skor) berdasarkan hasil cross-validation.

- Sumbu X: jumlah neighbors (k)
- Sumbu Y: rata-rata skor R² dari 5-fold cross-validation

Terlihat bahwa kinerja model meningkat hingga $k \approx 4-5$, lalu menurun seiring bertambahnya jumlah tetangga. Ini menandakan trade-off bias-variance, di mana terlalu sedikit tetangga menyebabkan noise (variance tinggi), sedangkan terlalu banyak menyebabkan over-smoothing (bias tinggi).

Evaluasi Model dengan Linear Regression

Kode juga akan menggunakan model Linear Regression untuk melihat apakah performa model menjadi lebih baik atau tidak. Berikut hasilnya:

```
--- Evaluasi Model Linear Regression ---  
RMSE pada set uji (Linear Regression): 5863.64  
R^2 pada set uji (Linear Regression): 0.77  
  
--- Evaluasi Model KNeighborsRegressor ---  
RMSE pada set uji (KNeighborsRegressor): 6206.28  
R^2 pada set uji (KNeighborsRegressor): 0.74
```

Berdasarkan data tersebut, kita bisa lihat bahwa Linear Regression ternyata merupakan model yang lebih baik dibanding KNN dengan nilai RMSE 5863 dan R2 sebesar 0.77.

Performa Model dengan Transformasi Log

Berikutnya, kita bisa melakukan transformasi log pada variabel target.


```
--- Evaluasi dengan Target yang Ditransformasi Log ---  
RMSE pada set uji (Target yang Ditransformasi Log): 5351.08  
R^2 pada set uji (Target yang Ditransformasi Log): 0.80  
  
--- Evaluasi Model KNeighborsRegressor ---  
RMSE pada set uji (Target Asli): 6206.28  
R^2 pada set uji (Target Asli): 0.74
```

Dapat dilihat, bahwa ternyata transformasi log membuat model lebih bisa menangkap pola-pola untuk memprediksi. Hal ini berarti data sebenarnya lebih cocok dalam domain log. Transformasi itu menghasilkan R^2 sampai 0.8.

Residual Plot dari Transformasi Log

Transformasi log pada target charges meningkatkan stabilitas dan kualitas prediksi model KNeighborsRegressor. Hal ini terlihat dari residual yang lebih simetris, pola yang lebih acak, dan variansi residual yang lebih seragam. Model tanpa log transformasi tampak bias terhadap nilai charges besar, menghasilkan residual yang besar dan tidak stabil.

Transformasi log pada target membantu menstabilkan varians error (mengurangi heteroskedastisitas). Model menjadi lebih baik dalam menangani nilai charges besar, meskipun belum sempurna.



Perbandingan Semua Model

Model	RMSE pada Set Uji	R ² pada Set Uji
KNeighborsRegressor (Baseline)	6206.28	0.74
Linear Regression	5863.64	0.77
KNeighborsRegressor (Log Transform Target)	5351.08	0.80
KNeighborsRegressor (Fitur children , region , sex dihapus)	4892.64	0.84

KNeighborsRegressor (Baseline): Memberikan peningkatan signifikan dibanding baseline, dengan RMSE 6206.28 dan R² 0.74, tapi masih belum optimal.

Linear Regression: Memiliki kinerja lebih baik dari KNN baseline, dengan RMSE 5863.64 dan R² 0.77, menunjukkan model mampu menjelaskan 77% variansi target.

KNeighborsRegressor (Log Transform Target): Transformasi log terhadap target meningkatkan performa, menghasilkan RMSE 5351.08 dan R² 0.80, menunjukkan prediksi yang lebih stabil.

KNeighborsRegressor (Fitur **children, **region**, **sex** dihapus):** Ini adalah model dengan performa terbaik. Menghapus fitur-fitur yang kurang relevan berhasil meningkatkan kinerja dengan RMSE terendah 4892.64 dan R² tertinggi 0.84, menandakan penyederhanaan fitur justru memperkuat akurasi model.